PETUNJUK PANDUAN RUNTIME

Jurnal Komputasi & Kecerdasan Buatan POKDARTIK

Nama Aplikasi:	chat_runtime_public.py
Model Target:	Gemma3-1B-IT-QNM4BIT (Kuantisasi U8/Q4M)
Penerbit:	Tim Perekayasa AI Independen POKDARTIK
Lisensi:	Non-Komersial (Hak Cipta © 2026 POKDARTIK)

Dokumen ini memberikan panduan langkah demi langkah untuk melakukan instalasi lingkungan eksekusi (runtime environment) dan menjalankan model Large Language Model (LLM) Gemma 3 hasil optimasi kuantisasi 4-bit secara murni menggunakan perangkat keras berbasis CPU.

Langkah 1: Persiapan dan Ekstraksi Model

Model disediakan dalam format arsip terkompresi ZIP untuk efisiensi unduhan. Ikuti langkah di bawah ini untuk mengekstrak berkas model:

1. Unduh berkas model terkompresi (misalnya `gemma3-1b-it-riset.zip`) dari portal jurnal CMS NgFlask POKDARTIK.
2. Ekstrak arsip tersebut ke dalam direktori lokal pilihan Anda. Sebagai contoh lingkungan kerja pada sistem operasi Linux:

```
mkdir -p /home/witi/data/
unzip gemma3-1b-it-riset.zip -d /home/witi/data/gemma3-1b-it-riset-nearest
```

Pastikan di dalam direktori ekstraksi tersebut terdapat berkas `config.json`, `tokenizer.json`, dan rangkaian berkas ekstensi `.safetensors` yang valid.

Langkah 2: Instalasi Dependensi Pihak Ketiga

Skrip runtime ini memerlukan beberapa pustaka eksternal utama untuk dapat mengeksekusi perhitungan tensor dan memetakan struktur arsitektur model Transformer. Jalankan perintah instalasi berikut menggunakan manajer paket Python (pip):

```
pip install torch>=2.2.0 transformers>=4.38.0 safetensors>=0.4.0
```

> **CATATAN TEKNIS CPU:** Runtime ini memanfaatkan fungsi pustaka internal khusus `_convert_weight_to_int4pack_for_cpu`. Pastikan instalasi PyTorch Anda mendukung set instruksi modern untuk akselerasi eksekusi matematika matriks tingkat lanjut pada CPU.

Langkah 3: Menjalankan Aplikasi Chat Runtime

Setelah seluruh komponen dependensi terpasang dan model telah diekstrak dengan benar, Anda dapat mengaktifkan antarmuka percakapan interaktif (Interactive Chat Interface) dengan mengeksekusi perintah Python berikut:

1. Mode Interaktif Standar (Rekomendasi)

```
python3 chat_runtime_public.py /home/witi/data/gemma3-1b-it-riset-nearest
```

2. Mode Satu Kali Eksekusi (Single-Shot Prompt)

```
python3 chat_runtime_public.py /home/witi/data/gemma3-1b-it-riset-nearest
--prompt "Jelaskan peran PokDarTIK"
```

3. Mode Pengujian Model Batasan (Baseline Softmax)

```
python3 chat_runtime_public.py /home/witi/data/gemma3-1b-it-riset-nearest
--attention softmax
```

Langkah 4: Manajemen Interaksi dan Perintah Konsol

Saat aplikasi antarmuka telah aktif di terminal, Anda dapat mengontrol sesi percakapan menggunakan perintah khusus berikut langsung pada kolom input pengguna:

- `/reset` atau `/new` : Membersihkan riwayat konteks percakapan saat ini untuk memulai sesi baru.
- `keluar`, `exit`, atau `/quit` : Menghentikan runtime aplikasi secara aman dan mengembalikan kendali ke shell terminal.